



Numerische Mathematik 1

Übungsblatt 12, WS 2019/20

– Musterlösungen –

Aufgabe 1 (Regressionsgerade)

Gegeben seien die Punkte $(x_i, y_i) \in \mathbb{R}^2$ für $i = 1, \dots, n$, $n \in \mathbb{N}$. Die *Regressionsgerade* ist diejenige Gerade

$$g(x) = ax + b$$

welche die Abstände $\|y_i - g(x_i)\|$ für alle $i = 1, \dots, n$ minimiert. Zeigen Sie, daß die Koeffizienten der Regressionsgeraden gegeben sind durch

$$\begin{aligned} b &= \bar{y} - a\bar{x}, \\ a &= \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x}\bar{y}}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)} \end{aligned}$$

Dabei sind $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ und $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ die Mittelwerte der Daten, $\text{Cov}(x, y)$ die *Kovarianz* und $\text{Var}(x)$ deren *Varianz*.

Musterlösung:

Zu minimieren ist die Fehlerfunktion

$$E(a, b) := \sum_{i=1}^n (y_i - (ax_i + b))^2$$

Die binomischen Formeln liefern

$$\begin{aligned} E(a, b) &= \sum_{i=1}^n (y_i^2 - 2y_i(ax_i + b) + (ax_i + b)^2) \\ &= \sum_{i=1}^n (y_i^2 - 2ax_i y_i - 2by_i + a^2 x_i^2 + 2abx_i + b^2) \end{aligned}$$

Setze nun den Gradienten von E gleich Null:

$$\frac{\partial E}{\partial b}(a, b) = \sum_{i=1}^n (-2y_i + 2ax_i + 2b) = 0$$

Dies ist genau dann der Fall, wenn

$$\sum_{i=1}^n ax_i + \sum_{i=1}^n b - \sum_{i=1}^n y_i = 0$$

also wenn

$$nb = n\bar{y} - an\bar{x}$$

bzw.

$$b = \bar{y} - a\bar{x}$$

Weiterhin gilt

$$\begin{aligned} \frac{\partial E}{\partial a}(a, b) &= \sum_{i=1}^n (-2x_i y_i + 2ax_i^2 + 2bx_i) = 0 \\ \Leftrightarrow 0 &= \sum_{i=1}^n (ax_i^2 + x_i(\bar{y} - a\bar{x}) - x_i y_i) \\ \Leftrightarrow 0 &= \sum_{i=1}^n (ax_i^2 - a\bar{x}x_i + x_i\bar{y} - x_i y_i) \end{aligned}$$

Dies ist genau dann der Fall, wenn

$$\sum_{i=1}^n (ax_i^2 - a\bar{x}x_i) = \sum_{i=1}^n x_i y_i - \sum_{i=1}^n x_i \bar{y}$$

bzw.

$$a \sum_{i=1}^n (x_i^2 - \bar{x}x_i) = \sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i$$

Löse nach a auf:

$$a = \frac{\sum_{i=1}^n x_i y_i - \bar{y} \sum_{i=1}^n x_i}{\sum_{i=1}^n (x_i^2 - \bar{x}x_i)} = \frac{\sum_{i=1}^n x_i y_i - \bar{y}n\bar{x}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}$$

Multipliziert man Zähler und Nenner mit $\frac{1}{n}$, so folgt die Behauptung.

Aufgabe 2 (Plotten einer Regressionsgerade mit Octave)

Ein überbestimmtes lineares Gleichungssystem $A\theta = b$ mit $A \in \mathbb{R}^{m \times n}$, wobei $m > n$, $\theta \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, kann in das quadratisches System der Form

$$A^T A \theta = A^T b$$

überführt werden. Die Lösung θ^* minimiert den Abstand $\|A\theta - b\|$. Schreiben Sie ein *octave*-Programm, welches dieses Gleichungssystem löst, wobei $A = (e \ x)$, $e = (1, \dots, 1)^T \in \mathbb{R}^m$, $b = y$ (x und y seien die x - bzw. y -Koordinaten der betrachteten Datenpunkte). Benutzen Sie dabei die Funktion `pinv` zur Berechnung der sog. *Pseudoinversen* von $A^T A$. Plotten Sie anschließend die Regressionsgerade, deren Koeffizienten durch den Lösungsvektor θ^* gegeben sind. Hinweis: Der Befehl `hold on` sorgt dafür, daß ein Plot beibehalten wird und etwas in den Plot hinzugefügt werden kann (ansonsten wird ein komplett neuer Plot erzeugt).

Musterlösung:

Das folgende *octave*-Programm liefert die gewünschte Regressionsgerade für zufällig gewählte y -Werte:

```
>> x = 1:10
x =

     1     2     3     4     5     6     7     8     9    10

>> y = rand(10) (1,:)
y =

    0.305264    0.120211    0.498296    0.210333    0.155803
    0.525931    0.025622    0.475793    0.286737    0.811778

>> plot(x,y,'rx')
>> X = [ones(length(x), 1) x']
X =

     1     1
     1     2
     1     3
     1     4
     1     5
     1     6
     1     7
     1     8
     1     9
     1    10
```

```

>> theta = (pinv(X'*X))*X'*y'
theta =

    0.160651
    0.032896

>> hold on
>> legend('Training data', 'Linear regression')
>> plot(X(:,2), X*theta, '-')
>> hold off

```

